Propuesta de tesis

Pronóstico de la demanda eléctrica horaria del Sistema Interconectado Nacional de Colombia: el aporte del volumen útil de los embalses en modelos de aprendizaje profundo

Sergio Castro Torres
Tania Liceth Barrera López
Universidad Externado de Colombia

Septiembre de 2026

Resumen

Colombia genera la mayor parte de su electricidad con agua, lo que hace que la operación confiable del sistema eléctrico dependa de pronósticos precisos de la demanda, especialmente en episodios de sequía como los del fenómeno de El Niño. Esta propuesta plantea evaluar si incluir el volumen útil diario de los embalses del país como variable adicional mejora la precisión de dos modelos de aprendizaje profundo –una red GRU y un Transformer– para pronosticar la demanda eléctrica horaria nacional, frente a modelos que solo usan el historial de consumo y el calendario. El estudio usa datos públicos de XM para el periodo 2015–2026, que incluye tres episodios de El Niño, y compara el error de pronóstico con y sin la variable de embalses, prestando especial atención a si la mejora es mayor durante los periodos de sequía. Se espera aportar evidencia concreta, y hasta ahora no documentada para el caso colombiano, sobre el valor de la información hidrológica en el pronóstico de la demanda nacional.

Palabras clave: pronóstico de demanda eléctrica, aprendizaje profundo, GRU, Transformer, hidrología, El Niño, Colombia.

1. Problema y contexto

1.1. ¿Por qué es importante pronosticar bien la demanda eléctrica?

Para operar un sistema eléctrico de forma segura, alguien tiene que decidir, con horas o días de anticipación, cuánta energía se va a necesitar. De esa decisión depende cuánta generación se programa: si el pronóstico se queda corto, hay riesgo de que falte energía; si sobreestima, se generan costos innecesarios. Por eso el pronóstico de la demanda de corto plazo es un problema clásico y bien estudiado en la literatura de sistemas de potencia (7; 9).

Colombia tiene una característica que hace este problema más interesante y más urgente: la mayoría de su electricidad se genera con agua. Esto significa que la capacidad de generación del país depende de cuánta agua hay almacenada en los embalses, y esa disponibilidad cambia

fuertemente con el fenómeno climático de El Niño. Durante el episodio de El Niño de 2015–2016, los embalses colombianos llegaron a caer entre 60 % y 70 % de su nivel, mientras que las altas temperaturas del fenómeno aumentaban el consumo de refrigeración (1). En el episodio 2023–2024, XM –el operador del sistema eléctrico colombiano– reportó los aportes de agua más bajos en 40 años (13). Y en el momento en que se escribe esta propuesta (septiembre de 2026), el país enfrenta un nuevo episodio de El Niño, con niveles de embalses ya por debajo de las metas de referencia y alerta activa del sistema (4).

En otras palabras: en Colombia, saber cuánta agua hay guardada no es un dato aislado del sector energético, es información que potencialmente puede ayudar a anticipar cómo se va a comportar el consumo eléctrico del país.

1.2. El aprendizaje profundo en el pronóstico de demanda

En los últimos años, los modelos de aprendizaje profundo se han vuelto una alternativa fuerte para este problema. Las redes recurrentes con compuertas, como la LSTM (8) y la GRU (3), procesan la serie de tiempo paso a paso, aprendiendo patrones de corto y largo plazo. Más recientemente, la arquitectura Transformer (15), que reemplaza ese procesamiento secuencial por un mecanismo de "atención" capaz de mirar toda la ventana de datos a la vez, se ha adaptado también al pronóstico de carga eléctrica: L'Heureux et al. (11) propusieron una versión de Transformer para este problema y encontraron que superaba a un modelo recurrente de referencia en la mayoría de los casos evaluados. Sin embargo, esa ventaja no es automática ni universal: Zeng et al. (17) mostraron que, en varios problemas de pronóstico de series de tiempo de largo plazo, modelos lineales muy simples pueden superar a variantes sofisticadas del Transformer. Esto quiere decir que cualquier comparación seria de modelos debe incluir también una referencia simple y exigente, no solo arquitecturas complejas.

En Colombia, los trabajos de pronóstico de carga con aprendizaje profundo existentes se han hecho a escala regional: Caicedo-Vivas and Alfonso-Morales (2) entrenaron una red LSTM para un operador de red colombiano con horizonte de siete días, y Restrepo Gil (12) pronosticó el consumo horario del departamento de Antioquia usando temperatura y tipo de día como variables adicionales. Ninguno de estos trabajos incluye variables hidrológicas, y ninguno se hace sobre la demanda agregada de todo el país.

1.3. El problema de investigación

De lo anterior surgen dos vacíos concretos. Primero, no se ha evaluado si el nivel de los embalses –información que en Colombia se actualiza y publica todos los días– aporta algo al pronóstico de la demanda nacional, más allá de lo que ya aportan el historial de consumo y el calendario. Segundo, tampoco se sabe si ese posible aporte es más importante justamente en los periodos en los que más importa acertar: los episodios de El Niño, cuando el sistema está bajo más estrés.

Es necesario aclarar, sin embargo, qué tipo de relación es razonable esperar. El nivel de los

embalses no explica por qué la demanda sube a las 7 de la noche y baja a las 3 de la madrugada –eso lo determina el calendario, no el agua almacenada–. Lo que sí es razonable esperar es que ayude a explicar el *nivel general* de la demanda en distintos periodos: por ejemplo, si las temperaturas más altas asociadas a El Niño elevan el consumo de refrigeración, o si las señales de escasez inducen campañas de ahorro como "Apagar Paga" en 2015–2016 (6). Esta propuesta no asume que esa relación existe; busca evaluarla empíricamente.

1.4. Pregunta de investigación

> *¿La inclusión del volumen útil diario de los embalses del Sistema Interconectado Nacional mejora la precisión de modelos de aprendizaje profundo (GRU y Transformer) para pronosticar la demanda eléctrica horaria de Colombia, en comparación con modelos que solo usan el historial de consumo y el calendario, y es esa mejora mayor durante los periodos de El Niño?*

1.5. Objetivos

Objetivo general. Evaluar si incorporar el volumen útil diario de los embalses del SIN mejora la precisión de modelos de aprendizaje profundo (GRU y Transformer) para pronosticar la demanda eléctrica horaria nacional, frente a modelos que solo usan el historial de consumo y el calendario, y si esa mejora es mayor en periodos de El Niño.

Objetivos específicos.

1. Construir una base de datos integrada de demanda horaria nacional (2015–2026) y de volumen útil diario de embalses para el mismo periodo, a partir de los datos abiertos de XM.

2. Describir la relación entre la demanda y el volumen útil de los embalses, distinguiendo los periodos de El Niño documentados (2015–2016, 2023–2024 y el episodio en curso desde 2026) de los periodos sin ese fenómeno.

3. Establecer líneas base de pronóstico (persistencia diaria y semanal) para comparar el desempeño de los modelos más avanzados.

4. Entrenar y comparar un modelo GRU y un modelo Transformer, cada uno en dos versiones –con y sin la variable de embalses– para el horizonte de 24 horas.

5. Evaluar si la mejora en precisión al incluir los embalses es mayor durante los periodos de El Niño que durante los periodos normales.

1.6. Justificación

Relevancia operativa. El país está atravesando, en este momento, un nuevo episodio de El Niño con los embalses por debajo de sus niveles de referencia (4). En ese contexto, cualquier

información que ayude a anticipar mejor la demanda tiene un valor práctico inmediato, no solo académico.

Aporte al conocimiento. No se identificaron, en la revisión preliminar de literatura, estudios que evalúen el valor predictivo del nivel de los embalses sobre la demanda eléctrica nacional colombiana. Esta propuesta llenaría ese vacío específico, además de extender a la demanda agregada del país una comparación entre arquitecturas GRU y Transformer que hasta ahora solo se ha hecho a escala regional en Colombia (2; 12).

Viabilidad. Los datos son públicos, gratuitos y ya fueron descargados y verificados: la serie de embalses (2015–2026) no tiene días faltantes, y la serie de demanda ya se construyó como prueba de concepto en un proyecto previo (sección 4.1). El proyecto no requiere recolectar datos nuevos ni depender de terceros.

1.7. Alcance

El estudio pronostica la demanda *agregada nacional* del SIN, en resolución horaria, a un horizonte principal de 24 horas (con el horizonte de 168 horas como análisis complementario). No se pronostican demandas regionales ni por agente comercializador, y el estudio evalúa valor predictivo, no relaciones de causalidad estructural entre la hidrología y el consumo.

2. Marco conceptual

Determinantes de la carga eléctrica. La literatura identifica el calendario (hora del día, día de la semana, festivos) y las condiciones meteorológicas como los determinantes principales de la demanda de corto plazo (7; 9). En Colombia, la demanda nacional muestra una estacionalidad diaria y semanal marcada, con mínimos de madrugada, máximos entre las 6 y las 8 de la noche, y menor consumo los fines de semana, patrón que ya se confirmó en el análisis exploratorio del proyecto previo (sección 4.1).

Redes recurrentes y Transformers. Las redes LSTM (8) y GRU (3) son el referente clásico para modelar series de tiempo con aprendizaje profundo. El Transformer (15), adaptado al pronóstico de carga por L'Heureux et al. (11), ha mostrado resultados competitivos, aunque Zeng et al. (17) advierten que su ventaja frente a modelos simples no es automática, lo que justifica siempre una línea base exigente.

Hidrología y demanda. La relación entre condiciones hidrológicas y demanda no es directa, pero hay al menos dos mecanismos plausibles documentados en la literatura: el climático, porque El Niño trae temperaturas más altas que aumentan el uso de refrigeración (1); y el de precios y ahorro, porque en temporadas de escasez el precio de la energía aumenta y se activan campañas de ahorro (14; 6). Estos mecanismos son la motivación para explorar la relación, no una conclusión anticipada.

3. Datos y metodología

3.1. Fuentes de datos

Variable	Definición	Fuente	Frecuencia
Demanda nacional	Suma horaria de la demanda real de todos los agentes del mercado (MWh/h).	XM (SIMEM)	Horaria
Calendario	Hora del día, día de la semana, festivo nacional.	Elaboración propia	Horaria
Volumen útil de embalses	Volumen útil diario del embalse agregado nacional (`AGREGADO_SIN`), en energía.	XM (SIMEM)	Diaria

Cuadro 1: Variables y fuentes de datos del estudio.

Los datos se descargan del portal público de datos abiertos de XM, SIMEM (`https://www.simem.co`), el administrador del mercado eléctrico mayorista colombiano (XM S.A. E.S.P.). La serie de volumen útil de embalses ya fue descargada para el periodo completo del 1 de enero de 2015 al 19 de septiembre de 2026 (4.280 días), sin días faltantes, usando el código `AGREGADO_SIN`, que corresponde al total nacional ya agregado por XM. Dado que las variables hidrológicas se publican a nivel diario y la demanda a nivel horario, el valor diario de embalses se mantiene constante durante las 24 horas de ese día al combinarlo con la demanda.

3.2. Periodos de El Niño considerados

Para evaluar si el aporte de la hidrología cambia según el régimen climático, se usarán los periodos de El Niño ya documentados en la literatura y en fuentes oficiales citadas en esta propuesta, en lugar de construir una variable climática adicional:

- El Niño 2015–2016 (1).
- El Niño 2023–2024 (13).
- Episodio en curso desde 2026 (4).

Los demás periodos del rango 2015–2026 se tratarán como periodos de referencia (sin El Niño).

3.3. Modelos

Se compararán cuatro alternativas para el horizonte principal de 24 horas:

1. **Persistencia (línea base).** El pronóstico es igual a la demanda observada 24 o 168 horas antes. No requiere entrenamiento y sirve como referencia mínima exigible.
2. **Regresión con rezagos.** Un modelo lineal simple sobre la misma ventana de entrada, como referencia adicional exigente, en línea con la advertencia de Zeng et al. (17).

3. **GRU.** Red recurrente con compuertas (3), entrenada en dos versiones: solo con historial de consumo y calendario, y añadiendo el volumen útil de embalses.

4. **Transformer.** Arquitectura basada en atención (15), inspirada en la propuesta de L'Heureux et al. (11) para pronóstico de carga, también entrenada con y sin la variable de embalses.

Comparar cada red neuronal con y sin la variable de embalses –manteniendo todo lo demás igual– permite aislar el efecto propio de esa variable sobre el error de pronóstico.

3.4. Evaluación

El conjunto de datos se dividirá cronológicamente en entrenamiento, validación y prueba, respetando el orden temporal para evitar fuga de información desde el futuro hacia el pasado, tal como recomienda la literatura de series de tiempo (10). Se reportarán tres métricas de error, todas de uso estándar en pronóstico de demanda: el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE). Para saber si la diferencia de error entre dos modelos es real o pudo deberse al azar, se usará la prueba de Diebold–Mariano (5), un método estadístico estándar para comparar la precisión de dos pronósticos.

4. Diseño del proyecto

4.1. Avance actual

Como parte del proyecto integrador de la materia de Aprendizaje Profundo, ya se construyó una prueba de concepto que sirve de punto de partida:

- Una serie continua de demanda nacional horaria para el periodo del 1 de enero de 2024 al 31 de octubre de 2025 (670 días), construida sumando la demanda de los agentes del mercado reportada por XM.
- Un análisis exploratorio que confirma los patrones diarios y semanales de consumo esperados.
- Líneas base de persistencia evaluadas sobre las últimas ocho semanas de esa serie (Tabla 2).

Línea base	**MAE (MWh/h)**	**RMSE (MWh/h)**	**MAPE (%)**
Persistencia $t-1$h	274.0	329.6	2.92
Persistencia $t-24$h	433.5	633.6	4.59
Persistencia $t-168$h	283.0	391.0	3.02

Cuadro 2: Desempeño de las líneas base de persistencia en la prueba de concepto (conjunto de prueba: 6 de septiembre a 31 de octubre de 2025).

Un hallazgo relevante de esta prueba de concepto es que la persistencia semanal (MAPE de 3.02 %) supera a la persistencia diaria (4.59 %) a 24 horas de horizonte, lo que indica que la línea base exigente a considerar no es solo la persistencia de 24 horas, sino también la de 168 horas.

Adicionalmente, ya se descargó y verificó la serie completa de volumen útil de embalses (2015–2026), descrita en la sección de datos, sin días faltantes.

4.2. Cronograma

Fase	Actividad	Entregable	Mes
1	Ampliar la serie de demanda a 2015–2026 y unirla con la de embalses.	Base de datos integrada	1–2
2	Análisis descriptivo de la relación demanda–embalses por régimen (El Niño / normal).	Informe exploratorio	2–3
3	Establecer líneas base (persistencia y regresión con rezagos).	Tabla de líneas base	3
4	Entrenar GRU y Transformer, con y sin embalses.	Código y resultados	4–5
5	Comparar modelos, aplicar prueba de Diebold–Mariano, analizar por régimen.	Tablas de resultados	5–6
6	Redacción del documento final y preparación de la sustentación.	Documento de tesis	6

Cuadro 3: Cronograma propuesto (6 meses).

4.3. Resultados esperados

Se anticipan tres escenarios posibles, todos informativos:

- **La hidrología aporta**, y ese aporte es mayor en los periodos de El Niño. Esto sugeriría que XM y otros actores del sector podrían beneficiarse de incluir esta variable en sus pronósticos.
- **La hidrología aporta poco o nada**. Sería un resultado igualmente válido: indicaría que el historial de consumo y el calendario ya capturan la información relevante.
- **Resultado mixto**: aporte solo en algunos periodos o solo en alguna de las dos arquitecturas, lo que abriría preguntas específicas para trabajo futuro.

Independientemente del escenario, el proyecto dejará como resultado una base de datos integrada y reutilizable, una comparación documentada entre GRU y Transformer para la demanda nacional colombiana, y evidencia empírica sobre un vacío de la literatura hasta ahora no explorado para el país.

4.4. Limitaciones

El estudio evalúa valor predictivo, no relaciones causales. El volumen útil de los embalses es una variable de evolución lenta (diaria), por lo que es más plausible que aporte al nivel general

de la demanda que a su patrón dentro de un mismo día. La identificación de los periodos de El Niño se basa en fuentes documentadas y no en un índice climático formal, lo que se señala como una simplificación deliberada frente a versiones futuras de este trabajo, que podrían incorporar aportes hídricos, temperatura y el Índice Oceánico de El Niño (ONI) como extensiones.

Referencias

[1] Asociación Nacional de Empresas Generadoras and Ministerio de Minas y Energía (n.d.). Resilience of electricity generation from hydropower in colombia: Coping with the el niño event and associated drought (2015-2016). Technical report, World Energy Council; Naciones Unidas.

[2] Caicedo-Vivas, J. S. and Alfonso-Morales, W. (2023). Short-term load forecasting using an lstm neural network for a grid operator. *Energies*, 16(23):7878.

[3] Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., , and Bengio, Y. (2014). Learning phrase representations using rnn encoder-decoder for statistical machine translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734.

[4] Delgado Gómez, P. (2026). Alerta en el sistema eléctrico: Ocho embalses de colombia operarían por debajo de sus mínimos históricos por el niño. *Valora Analitik*. 19 de septiembre.

[5] Diebold, F. X. and Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263.

[6] El Tiempo (2023). Fenómeno de el niño: Así se blindó colombia para no quedarse sin energía eléctrica. *El Tiempo*. 19 de mayo.

[7] Hippert, H. S., Pedreira, C. E., and Souza, R. C. (2001). Neural networks for short-term load forecasting: A review and evaluation. *IEEE Transactions on Power Systems*, 16(1):44–55.

[8] Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.

[9] Hong, T. and Fan, S. (2016). Probabilistic electric load forecasting: A tutorial review. *International Journal of Forecasting*, 32(3):914–938.

[10] Hyndman, R. J. and Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. OTexts, 3rd edition.

[11] L'Heureux, A., Grolinger, K., and Capretz, M. A. M. (2022). Transformer-based model for electrical load forecasting. *Energies*, 15(14):4993.

[12] Restrepo Gil, A. I. (2024). Hourly electricity consumption forecasting for antioquia-colombia using statistical-machine learning models. Master's thesis, Universidad Nacional de Colombia.

[13] Sandoval Mora, Y. (2024). Xm prende las alarmas y pide acciones para recuperar el nivel de los embalses en colombia. *Valora Analitik*. 25 de septiembre.

[14] Trespalacios, A., Cortés, L. M., and Perote, J. (2023). The impact of the el niño phenomenon on electricity prices in hydrologic-based production systems: A switching regime semi-nonparametric approach. *Energy Science & Engineering*, 11(5):1564–1578.

[15] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., , and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008. Curran Associates.

[XM S.A. E.S.P.] XM S.A. E.S.P. Simem: Sistema de información del mercado de energía mayorista. Portal de datos abiertos. https://www.simem.co.

[17] Zeng, A., Chen, M., Zhang, L., and Xu, Q. (2023). Are transformers effective for time series forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 11121–11128.